

四层验证：哪些辅助机制值得进入 Dynamics Atlas

- A 框题层：**达到本轮覆盖标准。拆题后两题的子问题覆盖中位数均提高，过强结论未增加。
- B 准入层：**文件可用性方案未奏效。自动检查6/6；但给Agent放入准入卡后，缺陷检测和降级仍为0/4。
- C 方法卡层：**未达非劣与增量标准。方法卡没有稳定优于七条协议；HSP90核心正确中位数2.5/5，对照协议4.5/5。
- D 结论上限层：**未达继续标准。仅ADK的组间错误中位数改善；HSP90与DHFR未改善，DHFR遗漏增加。

现在最重要的判断

保留科学问题与分析协议为中心；本轮只支持明确拆题带来的覆盖收益，未证明规则选择器或当前结论检查器有稳定增量。

方法卡在Q05与HSP90上的表现不同：旧规则在Q05较好，在HSP90较差。限定方法族检索没有消除操作不匹配。当前结果支持简化架构，不支持继续扩Rules来追逐问题表现。

一、从 Rules Table 起步，到当前真正得到什么

最初目标是从模拟、核磁和散射等不同来源资料得到有用、可核查、不过度的科学回答。早期整理33条候选规则，积累了分析前提与结论边界；Q05开发则暴露出关键方案仍主要由开发者安排。9月8日的项目报告与战略审查据此把科学问题和分析协议放回中心。

HSP90随后得到原生NOE与派生方向的实际对照；DHFR修正了包装坐标带来的假距离；ADK完成了完整分子距离准入和结构域描述。这些是科学资料与计算工作的成果。当前比较进一步检验：把哪些指导、检查或框题方式交给Agent，能在相同资料和工具上改变回答。

三个体系的来龙去脉、专业概念和数值见科学读本。这份报告集中说明四层比较与投入决定。

二、历史错误怎样约束这次设计

检查了8份原答，其中7份出现了本次记录的问题；保留13条相关观察、7个原因组。行数不是独立样本数，也不是Rules可以防住的错误数。最初表中一条证据不足的归因已经撤回，原稿和更正原因都保留。

编号	实际观察	原因组	当前结论检查回放
1	wrong threshold-specific initial direction counts	HSP_threshold_linkage	NO
2	4/20 vs5/20 internal inconsistency	HSP_threshold_linkage	NO

编号	实际观察	原因组	当前结论检查回放
3	50point opposite candidate falsely zero	HSP_threshold_linkage	NO
4	RMP special-method prerequisite transferred	RMP_scope_transfer	OUTSIDE_THIS_CHECKER_SCOPE
5	RMP prerequisite transferred in another output	RMP_scope_transfer	OUTSIDE_THIS_CHECKER_SCOPE
6	endpoint bins called regular	endpoint_wording	NO
7	A1 analyzes physically mismatched wrapped distances	DHFR_wrapped_input	OUTSIDE_THIS_CHECKER_SCOPE
8	A1 N18 near-distance percentage mistranscription	DHFR_A1_numeric_transcription	NO
9	A1 W22 near-distance percentage mistranscription	DHFR_A1_numeric_transcription	NO
10	A2 interprets erroneous large-distance tail as switching	DHFR_wrapped_input	OUTSIDE_THIS_CHECKER_SCOPE
11	A1 L28R N18 mean mistranscription reverses original-table direction	DHFR_A1_numeric_transcription	NO
12	constructed NOE bounds misaligned by atom pair	Q05_wrong_NOE_bounds	NO
13	acknowledgment overwrites scientific submitted answer	submission_preservation	OUTSIDE_THIS_CHECKER_SCOPE

最有信息量的零费用结果是：当前结论检查器在历史8份原答的回放中，未检出7处目标核心数值错误，唯一一条提示是误报。 正确单位 $\text{\AA}^{-1}$ 的指数-1被当作未匹配数字。另一个错误计算已经出现在工具日志中，所以可以通过“数字出现过”检查。原先3条“已回放检出”指两份DHFR输入检查和一份交付问题回放，不是这次结论检查器检出。

原答定位、具体引文和不同回放的范围见E0审计表与回放审查。

三、共同实验条件与评分边界

本轮计划72次四层对照，加2次ADK普通答复。实际完成74次尝试，保存74份合法答复。所有条件使用Luna medium、同一冻结容器与成熟工具，每题每条件4次，顺序预先随机化。ADK普通答复单列，不并入四次一组的效果比较。

普通组已经获得整理好的来源说明与派生表。当前测的是辅助组件在这一基线上的变化，不包括从原始论文自动发现问题、自动修理坏坐标和自动构建工具的总体能力。HSP90、DHFR和Q05已暴露；ADK仅一个新来源。

全部运行结束后统一隐藏条件，按五个冻结核心单元逐份评分；随后封存评分，再揭盲。以下正确、错误、过强结论与遗漏均为每题四次的中位数，原始分数全部保留。遗漏不等于明确说错；不必要弃权沿原计划操作定义包括可回答内容未覆盖。E2首次与最终提交另作对照。

当前评分者也参与建包，条件标签隐藏但不等于独立领域专家双盲。Claude核对了材料与设计，未替代这批答复的独立专家评分。详细过程、TOKEN_LIMIT处理和冻结后意见处置见方法与局限。

四、B准入层：自动核对与可信参照的贡献分开

普通组与卡组均为0/4检测、0/4降级。进一步查工具日志：四次卡组都列到了ADMISSION_CARD文件名，却没有读取其内容；故失败定位在准入结果未进入分析，不能据此断言Agent读懂卡后仍忽略。应由建包准入直接阻止坏表流入，不依赖Agent主动找卡。

纯代码检查检出6/6植入缺陷，3个干净包零误报。实际能力包括元数据与受信声明比对、行数和时间检查、矩阵与参照比对，以及读取上游物理检查结果。七个名称并不等于七种完整科学检查。三个干净包与参照完全相同，零误报是较弱的自一致性控制。

①包装坐标、②单位、⑤条件标签和⑥证据角色依赖数值或来源参照；③缺行也需要可信预期行数。④的时间单调可从表内检查，但对齐仍需参照。ADK全帧GROMACS核对提供独立数值证据，却不是另一份独立生成表上的误报试验。覆盖与容差见E1a能力审计。

科学问题	条件	n	核心正确 /5	核心错误	过强结论	遗漏 /5	新增费用 \$
DHFR缺陷表	准入卡	4	2	2.5	2	0	0.06495
DHFR缺陷表	普通资料	4	3	1	1	1	0.08190

五、D结论层：一次反馈实际改好了什么

三题中只有ADK达到错误中位数降低且遗漏不增加，少于预定2/3。

科学问题	条件	n	核心正确 /5	核心错误	过强结论	遗漏 /5	新增费用 \$
ADK结构域	普通资料	4	4	0.5	0	1	0.04915
ADK结构域	一次反馈	4	4	0	0	1	0.05112
DHFR修正表	普通资料	4	4	0	0	0.5	0.07312
DHFR修正表	一次反馈	4	3	0.5	0	1.5	0.08047
HSP90原生NOE	普通资料	4	3	0	0	1	0.06485
HSP90原生NOE	一次反馈	4	3.5	0.5	0	0.5	0.06709

9条实际提示均为数字追溯，未指向真实核心科学错误；反馈组12份初稿到终稿没有核心错误数减少。3份丢失可回答内容，其中一份同时削弱原错误并新增错误。ADK组间差异在初稿已存在，不能说由检查器纠错产生。

E2三题均没有PUBLIC_FACTS输入，证据角色分支未实际被测。数字出现、宽泛否定词和全文出现时间单位，都不能单独保证某一科学主张的来源、上限或统计解释正确。已运行后的意见没有用于回改检查器再测问题。实际提示及独立语义判断见E2提示逐条审查，首次/终稿分数见修订比较。

六、C方法卡层：检索命中能否带来科学收益

HSP90协议/旧规则/方法卡正确中位数4.5/2/2.5；Q05为4.5/5/4.5。方法卡未达到两个题都不劣于另外两组的冻结标准。

科学问题	条件	n	核心正确 /5	核心错误	过强结论	遗漏 /5	新增费用 \$
HSP90原生NOE	七条协议	4	4.5	0	0	0.5	0.07958
HSP90原生NOE	整段规则	4	2	1.5	0	1	0.07713
HSP90原生NOE	方法卡	4	2.5	0.5	0	0.5	0.07765
Q05纳米盘	七条协议	4	4.5	0.5	0	0	0.07105
Q05纳米盘	整段规则	4	5	0	0	0	0.05261
Q05纳米盘	方法卡	4	4.5	0.5	0	0	0.05776

三组全部没有肯定采用R0/dye/AV/RMP作为必要条件，零不适用术语无法区分它们。HSP90中BME重加权检查仍反复出现，但该项未在冻结词表内，只列探索性证据。Q05旧规则4份均覆盖五核心单元，必须保留这一收益，不能把混合结果概括为规则普遍有害。

HSP90按NMR方法族只取到1张BME重加权卡，Q05取到4张，DHFR和ADK的MD内部分析取到0张。HSP90当前NOE违例对照无需重新拟合权重。Q05因SAXS匹配还取到了针对平均FRET与聚合物分布的卡。实验方法相同，不代表当前操作相同。

冻结的主判据只统计肯定采用R0、dye、AV、RMP作为本题必要条件，否定或忠实介绍来源不计入。审查后提出的BME等词不追加加入主判据；若有不当迁移，在逐句探索性分析单列。更完整的设计解释见方法卡适用性分析。

七、A框题层：明确需求后多回答了什么

HSP90覆盖从2/3提高到2.5/3，ADK从2/3提高到3/3，达到冻结的2/2条件。

科学问题	条件	n	核心正确 /5	核心错误	过强结论	遗漏 /5	新增费用 \$
HSP90方向与参照	原题	4	2.5	0	0	2	0.06881
HSP90方向与参照	拆题	4	3	0	0	1.5	0.06479
ADK结构域	原题	4	4	0	0	1	0.04785
ADK结构域	拆题	4	5	0	0	0	0.04974

HSP90核心错误总数仍从1增加到2，虽中位数同为0；拆题提高了交付覆盖，不保证每份答案更准确。ADK拆题版完整交出分布中心与重叠。此比较增加了明确要求，不能解释为自主发现能力提高。

E4最终冻结按两道题的子问题覆盖改善判断，不按计划概览中的泛写三题。两版共用评分依据；拆题版要求更多内容，因此这是框题包的效果。正确覆盖更多要求值得记录，但不能据此宣称Agent自主发现问题的能力提高。

八、ADK普通答复与三个科学结果怎样交付

科学问题	条件	n	核心正确 /5	核心错误	过强结论	遗漏 /5	新增费用 \$
ADK结构域	普通资料	2	4.5	0	0	0.5	0.02329

ADK的独立复算支持：开态起始NMP-CORE首末变化+0.071 Å、LID-CORE +2.290 Å；闭态起始分别+1.091与+1.176 Å。全帧指定原子对与GROMACS差约0.005 Å；域间描述量由SciPy独立实现复算，差小于1e-10 Å。两个首末窗口都没有共同闭合，分布仍重叠。

这些来自项目预定的完整分子Ca距离，不是作者前向散射复现。沉积结构无ATP/AMP；实验为光释放ATP加AMP，温度和时钟不同。两份普通Agent到底做对哪些内容、与原文逐句是什么关系，见ADK原答与论文关系。

HSP90的10/20曾出现开放方向与原生NOE下9条仅相对趋开并不矛盾；DHFR的修正局部距离是开发者计算，旧原答未发现输入缺陷。这些边界在三个体系科学读本保留。

九、费用、时间与完整性

批次	实际尝试 / 计划	合法答复	费用 \$	上限 \$
E1b	8/8	8	0.14685032	0.20
ADK_plain	2/2	2	0.02328782	0.15
E2	24/24	24	0.38581429	0.55
E3	24/24	24	0.41578250	0.55
E4	16/16	16	0.23118686	0.40

新增合计 **\$1.20292179**，总上限\$1.85。对账的历史四批16份答复共\$0.28550861另列；它不是项目全部历史消费。ADK两份只在本轮ADK_plain记一次。没有以模型墙钟时间代替人工纠错时间，25%人工节省未测。

74份答复均完成并结清，无未知扣费。运行约90分钟；随后逐份盲评和交付整理单独计时。当前机器锁屏，未能再通过Claude完成最终独立答复抽查；已有两轮Claude材料/设计审查均保存，独立领域评分仍未完成。

十、下一步的投入决定

保留可审阅的七条协议与文献规则库，停止扩充选择器和通用结论拦截层。继续用明确科学问题、成熟计算和可复核报告交付结果；把问题拆成观测、幅度和结论边界。将准入结果接到建包流程本身，方法卡按具体操作适用性整理；新实现另做小型新题检验，不覆盖本轮原答。

不扩大33条注册表，不用同题修订后的重跑冲掉本轮失败，也不以本次小样本推算总体正确率。科学工作继续按具体问题、成熟方法、逐项证据和有限结论推进。组件若需要修正，只能作为明确的新版本，在新的问题与预先确定的判据下检验。

复核入口

- 一页结论 · 完整三体系读本 · 12页组会材料
- 逐份原始分数与条件 · 工作证据账本 · 偏离说明
- 如何查看原答和冻结输入 · 来源对应表 · 最终审查记录
- PR #27，保留原答、首次提交、工具输出、运行回执与费用。未合并。