

这轮比较实际检验了什么

这轮把“Rules Table 有没有用”拆成四个可分别失败的问题：输入核对结果能否改变 Agent 的判断；一次提交后反馈能否减少错误；方法卡是否比原有协议更适用；把科学问题拆明确能否增加有证据的回答。它们共同服务于最初目标：从蛋白动力学资料得到正确、有用、可以复核的科学回答。它们不是一项通用 Rules Engine 的验证。

资料、模型和公平比较

实验使用同一个 Luna 模型、medium 推理设置、同一个冻结容器和工具接口。每个条件每题运行四次，顺序在首次调用前随机化并保存。每次运行使用新的容器和上下文；评价 Agent 看不到评分依据、预期工具或开发对话。HSP90、DHFR和Q05属于已经研究过的材料；ADK是这轮新加入的一个来源体系。多个问题共享同一论文和数据，不能按题数当作独立来源数。

普通组已经拿到了整理好的来源说明和派生表。因此，它是“在相同整理资料上进行自主分析”的基线。数据整理、物理核对和准备工具所作的贡献不归入 Rules 的效果。修正表中的答案可以来自开发者的计算；只有评价 Agent 在运行日志中实际做出的分析，才能计入其分析行为。

每次运行最多40次工具调用、25分钟、累计160,000输入token和30,000输出token，容器无网络、只读资料目录和可写工作目录。各条件使用相同上限。达到token上限但已有合法提交的答复仍按正文评分，同时记录未完成状态；这不是无效样本，也不能仅凭个别上限事件认定某种提示导致能力下降。

为什么检查器通过还不等于科学问题解决

准入检查器实际比较来源声明、行数和时间、数值矩阵与受信参照，并读取外部物理检查结果。六种植入缺陷全部检出，是参照一致性测试的结果。三个干净包与参照完全一致，所以零误报主要是自一致性控制。独立坐标重算和GROMACS/VMD核对属于生成可信参照的上游工序，应单独展示。

七个检查名称没有对应七种完整科学推断：统计单位只是标签比对，时间单调不等于时间语义正确，观测窗口没有单独实现。多表或缺表的未覆盖输入还会触发断言异常。这些事实限制了当前检查器的用途：它适合冻结资料的回归核对，尚不适合单独承担陌生数据的科学准入。

结论检查器的数字匹配只证明某个数字出现在工具输出中，不证明它由正确原始量、单位和公式得到。历史回放已经给出反例：错误计算先写入工具日志后，数字仍能通过匹配；正确单位 $\text{\AA}^{-1}$ 的指数-1反而会被误报。将任意两个已有数字做加减除法来“放行”会扩大这个问题。未来的可追溯计算应把具体主张绑定到原始量和明确变换。

如何评分，什么算收益

全部运行结束后，最终答复去除条件名称、规则编号和运行编号，随机编码。评分先逐项记录五个冻结核心单元，再分开记录实际错误、过强结论、可回答内容遗漏、缺陷识别、下一步价值和成本。遗漏没有被说出的内容，与明确说错一个科学结果，是两类情况。原计划把“可回答但未回答”称为不必要弃权；报告保留这一指标，并说明它包括一般遗漏，不全是明确拒答。

每题按四次的中位数比较，同时给出逐份原始分数。E2首次提交与最终提交分别评分，先封存评分和时间，再揭示条件，随后核对每条检查提示是否真正指向科学错误。主评分不因揭盲后的期待而修改。若发现后续分歧，另列敏感性或审查意见。

评分人是当前Codex，也参与了建包。条件标签隐藏可以降低直接按组打分的风险，但不能消除建包者与评分者重合，也不能保证文本不透露是否收到了卡片或反馈。用户转交的Claude审查核对了方法与材料；它没有替代这批答复的独立领域专家评分。没有第二位评分者的结果，就不宣称双人一致性。

冻结后发现的问题怎么处理

第二次外部审查到达时，E2已经完成，E3已经运行。所有原题、评分依据、卡片、运行顺序和检查器保持不变。BME/MaxEnt等额外不适用术语不补进已经冻结的E3主判据；若答复把它们错误地当作本题前提，会以探索性逐句分析单列。E2三题没有PUBLIC_FACTS输入，证据角色分支不计作已测试功能。图像来源、单位缩放和心算的误报风险按实际发生情况报告。

E4的冻结文件按两道题的有支持子问题覆盖判断，与方案总表泛写的三题不同。两版共用评分依据，拆题版明确要求更多内容，所以可解释的是“框题包”的效果，不能直接解释为同样问题下推理能力提高。报告同时列核心正确和子问题覆盖，避免只用有利指标。

能做出的投入决定

四个每题四次的小比较可以支持保留、简化或暂不投入某个具体组件的决定。它们不提供跨蛋白总体正确率、稳定统计显著性或通用引擎必要性。没有前瞻记录人工纠错时间，就不宣称节省25%。计算费用、模型token、工具次数与墙钟时间分别列出。

科学结果继续按“问题—来源—方法—数值—结论边界”交付。若一个组件没有产生可见收益，它仍可作为文献或教学材料保存，但不继续占据系统核心。下一步由实际结果决定，不通过扩充规则数量延续架构。