

科学规则是否改善 Agent 回答

先读这一页

- 1. 两份新材料核对结果及其对设计的影响
- 2. 当前成果冻结在什么位置
- 3. 两个研究问题、比较对象和可能的误判
- 3A. 第一步为什么可以小，Agent能力却不能被做小
- 4. 七条 Active Rules 草案
- 5. 三组Agent到底看到什么、做什么
- 6. 隔离、人员和工具准备怎样落地
- 7. 四个新来源怎样选，怎样防泄漏
- 8. 隐藏评分要点怎样写和验收
- 9. 逐步执行顺序
- 10. 同预算、超时与失败怎样定义
- 11. 评分与分析细则
- 12. 投入阈值、混合结果和停止条件
- 13. 七个工作日的任务、验证预算与交付
- 14. 只保留五类交付
- 附录A 开发问题和提示模板
- 附录B 一次运行怎样从资料走到最终答案
- 附录C 提交给Pro的审查问题
- 来源与既有分析

Dynamics Atlas 下一阶段逐步执行计划 · 2026年9月9日 · 待 Pro 审阅草案

Dynamics Atlas tests whether explicit, source-grounded scientific rules improve a tool-using LLM agent’s ability to produce useful, evidence-bounded answers from heterogeneous protein-dynamics data.

Dynamics Atlas 研究显式、可追溯的科学规则，能否让使用工具的 LLM Agent 在异质蛋白动力学资料中给出更多正确、有用、不过度的科学回答。

本轮交付是实验计划。尚未启动开发比较或正式测试，未选择正式题，未改 Q05/Q15，也没有把本稿提交给外部模型。用户将本稿交给 Pro 审查，收到通过意见后再进入执行。下文所有预算、阈值和运行安排均为本次待审提案。

先读这一页

我建议采用 Pro 的主方向，将接下来的工作集中在两项可失败的比较上。第一项比较 Agent 单独工作与获得七条科学规则后的回答。第二项比较 Agent 已经读过这些规则时，少量确定性拦截是否还带来额外收益。原有科学分析保留为开发资料，不能继续作为正式验证样本。

这次需要做出的研究判断很具体。研究者交给 Agent 一份真实蛋白资料，Agent 要自己阅读、选择已有分析工具、执行并形成答案。我们观察规则是否帮助它多回答一个重要问题、避免一项真实科学错误，同时有没有增加无谓弃权和成本。规则数、运行成功数及拦截次数都不是主要成果。

计划保留三组、两个开发案例、四个新来源组和每组两次独立运行。正式输出为24份，独立来源单位仍只有4个。开发先跑6份；若需要修订，只能合并改一次，再完整重跑6份。因此正常研究运行最多36份，另允许最多两次有记录的基础设施替代尝试。

对 Pro 原稿作出以下实质修订。

原稿需要补清的地方	本计划怎样处理
Rules Table 是否有价值与表格形式是否有效容易混同	B-A测提供该科学指导包的总效应，包括知识、组织和提醒；不声称已隔离表格形式本身
C可能从后台获得额外知识或隐藏答案	C只执行公开给B/C的两个有限判断；所用来源事实三组完全相同；隐藏评分要点不能被执行器读取
fresh session可能仍能读取整个项目	在操作系统或容器层限制文件和网络；新的聊天窗口本身不算隔离
四个来源、两次运行容易被误当成24个独立样本	逐来源报告配对差异和两次波动；不作总体显著性、等效性或泛化结论
“重要改善”“明显弃权增加”尚无判定方式	提前定义重要结论单元、错误类别和投入阈值，见评分及决策部分
原三种结果没有覆盖无效实验和混合结果	先判断实验是否有效，再选择路线；缺失或污染不能被写成Rules没有价值
七天表默认专家和运行环境已经到位	明确人力、预算和技术入口；七天按具备条件后的工作日计算

明天讨论时最值得确认的是，这样的实验是否足以决定下一阶段投入。它还不承担“Rules普遍提高科学正确率”的结论。

1. 两份新材料核对结果及其对设计的影响

1.1 你所指的两份材料

第一份是 Minhuan Li、F. Emil Thomasen、Pilar Cossio 的博客 **Are We Capturing the Ensemble?**，日期为2026年8月31日，副标题讨论结构生物学实验会保留、模糊或丢弃哪些分子分布信息。[S1]

第二份是 Soumendranath Bhakat 的 **Benchmarking Generative AI and Physics-Based Molecular Simulation for Sampling Conformational Heterogeneity in T4 Lysozyme**, JCIM, 2026年9月3日在线发表, DOI为10.1021/acs.jcim.6c02044。分析时必须同时使用主文和Supporting Information。[S2、S3]

它们分别是一篇概念性博客和一篇具体系统研究。Pro原稿提到的Data Agents、DataSpace、Toolathlon等属于额外的Agent方法文献, 不是这次所指的两份材料。本稿没有重新核验这些额外论文的原始实验, 因此不把其中的层级或性能数字作为本研究设计成立的证据。

本轮复用了已有、来源匹配的Markdown衍生件, 重新阅读博客全文相关段落, 并核对JCIM主文Fig.4及SI的S1、S6、S7原图。公开检索确认了JCIM题名及发表日期; 博客的在线重开失败, 其内容依据本地完整正文和此前来源记录。[S1至S3]

1.2 博客讨论的核心是可区分性

蛋白质可以处于许多构象, 每种构象可能有不同出现比例。博客把科学问题写成一条信息传递过程。研究者感兴趣的分布, 未必等于样品制备后进入仪器的分布; 仪器把构象转换成信号, 后续筛选、重建、聚类或平均又把信号转换成我们实际分析的数据。每一步都影响哪些分布差异还能够被分辨。[S1, What distribution enters the experiment?及How processing can wash out the source distribution]

博客用前向关系解释为什么“测了平均值”仍可能约束多个状态。两个构象的平均信号一般是各自预测信号的加权和, 不能用平均结构的预测代替。单分子测量也需要经过探针、噪声及处理模型; 保留单分子观测并不等于直接看到了真实构象分布。单分子FRET时间轨迹可能包含粗状态转换信息, 而单颗粒冷冻电镜通常不保留同一分子的时间顺序。[S1, How experiments constrain the source distribution]

原文提出的ensemble resolution, 是对“当前测量和处理还能区分哪些分布差异”的提问。它没有给出适用于所有实验的一个分数, 也没有提出Rules Engine。两组系综可能主要状态相同、比例不同, 或边缘分布相似、相关运动不同; 一种数据能够辨认其中某种差异, 不代表它也能辨认其余差异。[S1, The question of ensemble resolution]

对本计划的修改是先定义要区分的科学解释, 再评价Agent。每个隐藏评分要点都必须写清“哪些解释已被证据区分, 哪些仍等价”, 而不能只列应触发的规则。公开资料必须保留必要的测量和处理说明。只提供共识密度图时, 不能要求Agent恢复已经丢失的群体信息; 提供原始分布且足以比较时, 也不能奖励它一概弃权。

一个仅用于讲清设计的构造例子是, 两套候选分布给出几乎相同的平均读数, 却在一段实验可分辨的分布尾部有差异。评分要点应检验Agent是否利用尾部信息, 或是否明确尾部噪声使两者仍无法区分。这个例子不是博客中的实测结果, 也不会充当正式蛋白案例。

1.3 T4L论文给出正面采样证据, 同时留下不同层次的问题

T4溶菌酶是一种具有域间开闭运动的蛋白。作者将域间几何与Phe4侧链的暴露程度结合, 划分暴露/开放、暴露/闭合、埋藏/开放、埋藏/闭合四个区域。生成模型、生成结构与分子模拟结合的AMS, 以及增强分子模拟EMD, 在这些区域中的覆盖不同。四区划分便于比较, 但会省略每个区域内部的连续差异。[S2, Fig.2至Fig.3及Methods]

论文确实有相同生产模拟时长的比较。Fig.4将常规MD的20条1 μ s轨迹，与AMS首轮100条200 ns轨迹比较，总生产模拟时间均为20 μ s。完整AMS方案还包括第二轮80条200 ns，总计36 μ s。因此可以讨论给定播种策略在有限生产模拟预算内的覆盖优势；不能把它说成所有生成、预处理和计算开销均相同的总体效率排名。[S2, Fig.1、Fig.4]

作者使用马尔可夫状态模型，即利用状态之间的时间转换估计状态权重的模型，给出群体估计和相关诊断。SI中暴露/闭合区域的作者报告值为AMS 0.7%，95%区间0.6%至0.8%；EMD 3.9%，区间3.5%至4.2%。这两个数是各自分析下的模型估计，不是该物理系统已经确定的唯一真值，也不能直接把EMD设为全局标准答案。[S3, PDF第5页S6、S7]

SI的S1同时呈现了与实验单分子FRET分布的相同部分和差异。高效率区域有对应信号，约0.6附近仍可看到AMS与实验的分布结构不同。图形差异尚未在本项目中经统一误差模型量化，不能直接判定整体方法失败；同样，覆盖到稀有闭合区域也不足以认定完整实验分布已复现。[S3, PDF第1页S1]

对本计划的修改是给T4L开发题同时设置正面与限制性评分单元。好的答案应保留给定预算下的覆盖证据，区分估计权重与真实平衡比例，并说明FRET和时间诊断分别支持什么。只写“没有完全验证，所以不能判断”会丢失已知成果，也会被计为无必要弃权。开发题读取主文和SI即可，不要求重新生成轨迹或复建MSM。

1.4 两份材料怎样进入研究，而不扩成更多规则

原始材料提供的概念或证据	本计划中的具体位置
所关注的分布与实际样品分布可能不同	规则2保留条件及制备差异；隐藏要点写明答案适用对象
测量信号与结构描述不同，处理也改变可见信息	规则3同时间native observable与数据处理；规则6检查前向关系
能区分某个分布特征不等于辨识整个分布	规则1定义目标；规则7记录未排除解释
AMS存在真实覆盖优势，也存在权重及分布差异	评分同时奖励正确正面结论、处罚过度结论和无必要弃权
相同生产时长仍需说明起点和额外成本	三组固定模型、资料、工具和预算，单独报告准备与执行成本

这些是本项目从材料中作出的设计推论。两份来源本身没有验证LLM使用Rules的效果，也没有证明七条、四个来源或两次重复是统计上充分的样本量。

2. 当前成果冻结在什么位置

Q05固定保留SAXS-only $\theta=6$ 和 $\theta=60$ 、两类NOE预测、作者权重、旧联合权重及逐项独立复核。主设置下SAXS平均惩罚10.0188→1.1707，酰胺NOE 0.9334→0.9647，甲基NOE 3.8931→4.4695。它是已暴露的开发成果，未证明Rules独立提升回答质量。[S4]

本阶段不扫描 θ 、不追论文汇总6.0、不做新联合求解、不补形状，不为Q05新增规则或修旧流程。开发实验中的fresh Agent可以自主选择调用给定工具；这些调用只用于测试新实验装置，不能回写或升级已冻结的Q05科学结果。

Q15只作历史失败资料，原20题统一称为开发、需求和回归资料池。同一论文的多个题、共享实验或预测矩阵的题不算独立来源。已有33条候选规则 and 原执行实现继续保留，本阶段不删除，也不把其全部内容提供给测试Agent。[S5]

项目原始科学目标仍是可靠理解异质蛋白资料。本次研究把“规则是否有帮助”作为服务这个目标的独立假设。上述统一目标句先用于本阶段协议；通过审查后才更新项目README及后续报告的阶段说明，保留历史科学结果和原始使命的来由。[S6]

3. 两个研究问题、比较对象和可能的误判

比较	要估计的效果	可以支持什么	尚不能区分什么
B-A	给Agent七条可读、带来源的科学指导包	指定任务和模型下，指导包是否提高有用正确回答或减少错误	额外知识、提醒、组织方式、增加阅读文本各自的贡献
C-B	同样指导包之上增加两个有限确定性检查及一次反馈	这套具体执行政策是否进一步改善最终交付	所有Rules Engine或任意自动科学审查的效果

B与C同时观察，第二个问题的继续投入决定以第一个问题的结果为主要前提。若B没有增益而C有增益，必须如实报告这个混合结果，不能硬写成所有规则都无用。可能需要另外设计不含完整Table的小检查对照，见第12节。

目标Agent是在给定成熟工具和资料范围内，自己安排阅读与分析步骤。研究者给科学问题，Agent选择方法，运行后按证据回答。当前已有的Profiler/Planner调用和确定性路径不能直接当作符合这个条件的完整Agent基线。第一天必须确认存在真实的多步工具调用，而不是开发者先选好算子，再让模型填配置。[S7]

本稿不以L2或L3标签作为通过标准。可观察标准是工具选择、真实执行和最终科学答复，不要求Agent发明算法、写新科学算子或拥有最终领域认可权。

3A. 第一步为什么可以小，Agent能力却不能被做小

用户补充的担心成立。如果所谓Agent只是读一张表，再按预写步骤调用一个函数，这个实验测到的主要是提示词遵循，难以说明科学Agent的价值。第一步应当简化处理差异，同时保留完整的工具使用能力。

本计划将harness理解为支撑Agent持续工作的运行系统。它负责把资料 and 工具接给模型，执行模型选择的动作，返回结果，控制资源并保存证据。模型在这个系统内安排分析过程。Rules Table是一种可加入的科学指导，确定性检查是另一项可加入的执行政策，两者都不等于完整harness。

三组共同的基础 harness

阅读原始资料 ⇌ 自主安排和调整分析 ⇌ 调用工具并读取结果 → 形成有证据的回答

- A 共同基础
- B 共同基础 + 可读 Rules
- C 共同基础 + 同一 Rules + 两项确定性检查

本轮三组都应有的能力

共同能力	可以观察到的行为	不应由开发者代做的部分
理解任务与定位资料	从科学问题选择要读的文件和片段	不先把关键图和预期答案提取给某组
自主安排分析	在现有工具之间选择有信息价值的步骤；资料够用时直接回答	不把Q05的SAXS-only路线写成固定 workflow
执行并读取真实结果	调用工具，检查输出含义和错误，必要时修正自己的代码	不把预计算结论伪装成Agent自行完成
根据结果调整下一步	数值或文件结果不支持原判断时，改变下一项检查或缩小结论	不由外部开发Codex及时提示它遗漏了什么
保存并使用证据	同一会话内保留所读来源、计算输出和未解问题，最终形成有用答案	不由另一个有隐藏答案的整理器补齐最终结论

这些能力都属于A/B/C共同基础。正常工具错误反馈、会话内工作笔记和预算内的分析修正三组都保留。C只多两项预定的科学角色检查，不能独享更强的规划器、更好的记忆、更长的反思流程或额外工具。

一个具体开发过程可以是Agent先读数据角色，提出一个可区分的科学问题，选择已有计算，读到与预期不同的结果，再决定补查误差或只报告局部答案。这个过程的实际路径由Agent产生；评判者评价它是否有效，不把某条开发者预想路径作为唯一正确路线。

后续科学harness怎样发展

第一步回答最小增量问题，后续才决定哪一种运行能力值得专门研究。可能的候选包括来源与条件追踪、跨工具结果传递、根据数值证据调整计划，以及在局部失败时保留可答部分。每个候选都需要由真实运行失败支持，不能因为听起来完整就一起开发。

后续比较应把同一基础Agent接到两个harness版本上，固定模型、数据、工具和资源，只改变一个具名能力，再用新的来源评价。规划或证据追踪模块如果多用了模型调用，其成本也必须计入。不能把五项能力一起改进后的收益全部归因于Rules。

因此，第一轮Table没有增益，只会削弱“这七条指导值得作为研究中心”的依据；它不否定工具执行、证据追踪或更好的harness设计。若Table有益而两项拦截无益，最自然的方向可能是保留科学指导和一个能工作、易检查的harness。若当前共同harness本身经常丢工具结果，应先报告运行基础的缺口，本轮不把它包装为Rules失败。

这部分是后续研究路线，不增加本轮实验数量，也不批准新框架开发。第一步结束后仍须依据实际结果决定继续研究哪个具名功能。

4. 七条 Active Rules 草案

以下七条是将已有科学原则整理成可执行提问的**候选文本**，不是七条作者原话，也尚未冻结为实验v1。每条只保留同一组八个字段。B与C读取完全相同文本；A不读取该表。来源在文末，正文不含内部规则编号、绑定号或执行状态码。

规则一 明确要回答的科学量

- **Rule** 当前问题要求区分哪一种科学结果？
- **Why** 几何、群体比例、动力学、观测信号和功能机制所需证据不同。
- **Applies when** 提问或答案在这些结论之间发生转换时。
- **Evidence needed** 目标量、适用对象，以及直接支持它的观测或计算。
- **Allowed conclusion** 给出已被支持的那一层结果及条件。
- **Forbidden upgrade** 从闭合样结构存在直接推出其平衡比例、转换速率或功能机制。
- **Possible action** 把问题拆成可回答和仍待证据的部分，保留已回答内容。
- **Source** [S1] The question of ensemble resolution；[S2、S3]覆盖、权重与实验比较。

规则二 明确物理对象和条件之间的关系

- **Rule** 这些资料的蛋白对象和实验条件支持怎样的比较？
- **Why** 构建体、突变、配体、寡聚状态、温度、环境、标记及制备会影响实际样品。
- **Applies when** 合并或比较不同实验、模拟或样品时。
- **Evidence needed** 来源中的对象和条件说明，差异及需要使用的桥接假设。
- **Allowed conclusion** 明确适用对象及假设后的比较，或不依赖未解差异的局部结果。
- **Forbidden upgrade** 把不同对象无说明合并；也不能仅因一个条件缺失而否定所有可比结果。
- **Possible action** 核对原始方法和对应关系，说明哪一项差异实际影响当前问题。
- **Source** [S1] What distribution enters the experiment?；[S8]标记、条件与跨观测解释。

规则三 识别实际观测量及其处理过程

- **Rule** 数据实际记录什么，处理后仍保留什么信息？
- **Why** 同叫distance的字段可能表示骨架距离、探针距离或由效率反演的量；分布和均值也不同。
- **Applies when** 解释表格、分布、密度图或跨技术比较时。
- **Evidence needed** 原生读数、单位、聚合方式，以及筛选、重建和转换说明。
- **Allowed conclusion** 在该读数与处理保留的信息范围内作判断。
- **Forbidden upgrade** 把字段同名当作测量等价，把处理后表示直接当作完整分子分布。
- **Possible action** 优先在可比的观测空间比较，必要时回看原始或更少处理的数据。
- **Source** [S1] How experiments constrain...及How processing can wash out...

规则四 区分统计单位、采样和时间证据

- **Rule** 这些数据的独立单位是什么，是否保留支持时间结论的顺序和采样信息？
- **Why** 相关帧、不同起点或无序结构集合不能自动提供独立重复或转换速率。
- **Applies when** 报告置信区间、状态比例、稀有状态或动力学时。
- **Evidence needed** 重复单位、时间顺序、采样政策、观察窗口及所用模型诊断。
- **Allowed conclusion** 描述覆盖、模型条件下的估计，或在足够时间证据下报告动力学量。
- **Forbidden upgrade** 把帧数当独立样本，把静态覆盖当平衡概率，把有限轨迹直接当可靠速率。
- **Possible action** 按合适单位比较、检查相关性或时间诊断；缺时间证据时保留几何结果。
- **Source** [S1]单分子与单颗粒之别；[S2、S3] AMS及MSM方法与诊断。

规则五 标明证据的使用角色

- **Rule** 当前证据是否已用于拟合、校准、候选生成或方法选择？
- **Why** 同一数据上的拟合改善与新信息上的预测检验支持不同强度的判断。
- **Applies when** 评价模型、更新权重或宣称验证时。
- **Evidence needed** 实际拟合目标、训练或校准信息及重复使用记录。
- **Allowed conclusion** 准确标注的拟合结果、条件性预测或有充分独立性依据的验证。
- **Forbidden upgrade** 把已参与拟合的数据称为独立验证；信息角色未知时不能推定独立。
- **Possible action** 检查输入与目标函数，寻找未参与选择的证据或明确保留角色不确定。
- **Source** [S9]联合与单观测重加权设计。

规则六 检查前向模型和探针关系

- **Rule** 如何从候选结构预测当前实验读数，该关系适用于此问题吗？

- **Why** 结构到信号可能涉及探针、非线性平均、取向、时间尺度和模型误差。
- **Applies when** 用结构解释FRET、DEER、NOE、散射或其他实验时。
- **Evidence needed** 前向关系及单位、平均方式、参数适用范围和不确定性。
- **Allowed conclusion** 在该关系与误差假设下的预测比较。
- **Forbidden upgrade** 未经模型把结构距离等同于FRET效率，或先平均结构再替代平均信号。
- **Possible action** 选择给定成熟工具或等价计算，解释残差，指出前向模型未解决的部分。
- **Source** [S1]平均观测公式；[S9]纳米盘前向预测与重加权。

规则七 说明能排除什么，以及下一步怎样区分

- **Rule** 当前证据排除了哪些解释，哪些解释仍然都成立？
- **Why** 符合若干观测不保证唯一结构、唯一权重或唯一机制。
- **Applies when** 多个模型都能解释结果，或答案涉及完整ensemble解释时。
- **Evidence needed** 被比较的解释、预测差异、误差和可辨认范围。
- **Allowed conclusion** 明确已确定部分、仍等价的解释，以及有区分力的下一项证据。
- **Forbidden upgrade** 从一个好拟合选出唯一真分布；或因某部分未解而取消已有正确答案。
- **Possible action** 比较替代解释，提出能区分它们的具体读数或分析；证据已经够用时直接回答。
- **Source** [S1]ensemble resolution；[S2、S3]不同层次的采样与实验结果。

本表把不确定性放入相关规则，避免漏掉误差模型；不新增第八条通用“再检查一次”。通过开发冻结时，目标是控制为2至4页可读材料。

5. 三组Agent到底看到什么、做什么

5.1 共同可见内容

三组得到同一科学问题、同一原始论文和SI、同一数据、同一工具及其方法文档、同一输出格式。文件索引只说明文件类型和来源，不提供使用的分析、目标数值、错误提示或规则对应。完整论文中本来就包含作者解释，这是任务证据；额外的开发结论摘要和标准答案不进入工作区。

公共资料中的事实必须有定位。例如某个数据集是否参与拟合，只能引用作者方法或实际输入记录。若curator为方便读取制作事实清单，它必须对三组相同，逐项有来源，未知项保留未知，不能写“因此应弃权”之类判断。清单及处理成本计入人工准备。

正式运行默认离线阅读已封装来源，不开放自由联网。模型服务连接单独开放，科学工具不访问模型以外的网络。这样避免不同运行获得不同论文、答案网页或Rules。它检验给定资料中的分析能力，不能解释为开放网络文献发现能力。

5.2 共同工具范围

第一天锁定同一小工具包，优先复用现有文件读取、PDF/Markdown检索、Python、NumPy/SciPy、绘图及已验证的数值函数。需要重加权、误差传播或已有前向矩阵评价时，工具描述只说明输入、输出、适用条件和错误信息，不指定某个case应调用它。

不把旧Q05的“推荐SAXS-only”“联合目标配置”作为Agent可见的任务安排。旧科学结果和配置留在开发参考区。各组可以自己编写短分析代码调用已有方法，但不能安装包、生成新科学算子供后续case复用、启动新MD或访问集群。

当前机器有Codex及Docker命令入口；这只证明程序存在。已查看的旧运行模块主要是Profiler/Planner提案传输，正式研究所需的端到端隔离、计量和工具循环尚未验收。[S7]第一天优先核实并复用已有完整工具型Agent运行入口，只允许做一个小的运行适配；不要求四小时内从头开发harness。四小时内若无法证明公平隔离和预算约束，就停在环境未就绪，不以现有半预写流程代替Agent实验。

5.3 共同输出及其测量代价

最终答案保留五部分。

- 1. bounded_answer，逐条有用的科学结论及条件。
- 2. evidence_used，使用的原始来源或真实计算输出。
- 3. analysis_performed，实际做过的分析；不要求提交私有推理过程。
- 4. unresolved_alternatives，资料仍无法区分的解释。
- 5. next_action_if_needed，有必要时的具体下一步；证据足够时允许为空。

为使C的有限检查可以确定性执行，五部分中的结论记录还需附相同的简短字段，见附录B。三组都使用这些字段。它们会让A也注意到证据类型和角色，因此本实验的A准确名称是“具有共同证据输出格式、没有七条Rules的Agent”。B-A是在这个较强基线上增加规则文本的效果，不能宣传成与完全无科学结构提示的Agent比较。

5.4 唯一处理差异

项目	A	B	C
问题、来源、数据、工具、预算、输出格式	相同	相同	相同
七条规则及其引用	无	有	与B相同
公开的两项确定性检查定义	无	包含在规则附注，可自行遵循	同样附注，并由程序执行
最多一次固定提交后修订机会	有，共同格式反馈	有，共同格式反馈	有，共同格式反馈及实际冲突信息
额外科学工具、人工帮助或隐藏评分要点	无	无	无

B/C附注不能加入第八条知识，只把规则4和5中的两个明确禁止升级写成可执行条件。C-B估计的是这些检查、反馈与发布限制的组合效果。它没有覆盖完整旧Engine，因此结果不能外推到33条规则及其全部执行系统。

5.5 C只先检查两种明确矛盾

拟合与独立验证冲突。 结论把一个具名数据对象标为独立验证，而该对象公共记录明确显示参与了本次拟合。系统指出冲突及来源，要求修改该结论的角色。它不判断没有参与拟合就一定独立，候选生成与历史选择的泄漏仍需Agent解释。

静态资料与新推断速率冲突。 Agent声称从所引用资料重新推得转换速率，而引用对象全部明确为无时间顺序的静态集合，且不存在时间或其他有效速率证据。系统限制这条升级。若Agent是在准确转述论文已报告的速率，或引用实际时间资料，不能按静态集合规则拦截。

未知元信息不能自动转为负面事实。字段和文本矛盾、引用遗漏、委婉绕开标签等情况仍可能漏检，全部保留给盲评分。一次确定性检查通过不等于科学正确。

C保留提交前原稿、冲突反馈、修订稿及最终展示内容。修订后仍冲突时，只限制那一条结论，并保留其他答案及受限原因。主评分看用户最终可见内容，同时报告原稿与拦截效果；删掉正确结论会降低有用答案分数，增加无必要弃权。不能用“拦截成功”覆盖这些损失。

6. 隔离、人员和工具准备怎样落地

6.1 开发者与被测Agent的边界

Development Codex可以读取科学答案、准备工具和评判标准。Evaluation Agent每次从空白消息和新工作目录启动，只能读取封装的公共case、共同方法文档及本组允许的规则文件。

隔离需要真实文件与网络权限。只换聊天窗口、使用worktree或把答案放在相邻目录，都不够。测试进程不能看到项目根目录、AGENTS.md、记忆目录、旧任务历史、开发报告、隐藏评分要点及其他运行的输出。模型认证由受信任的启动端处理，不把凭据或整个用户目录挂到科学工具工作区。

优先用现有运行设施的受限文件挂载和网络控制。实施时只允许一个薄启动脚本和一个小的确定性检查模块，不建立多Agent框架。启动脚本负责新会话、预算、工具转发和日志；科学步骤由Evaluation Agent选择。

在任何开发模型调用前，运行一次合并的非模型检查。放置一个工作区外的诱饵文件，验证读取失败；检查符号链接逃逸、隐藏目录和禁止网络访问；确认A只缺规则处理，其余公共文件一致。未通过则所有组都不能开始。这项检查的成本是隔离验收，不是规则科学增益。

6.2 角色与人力

角色	负责内容	不负责什么	预计投入，待确认
Development Codex	七条规则、公共工具、运行适配、评价规范及开发修改	不在正式运行中指导 Agent	约1至2个工作日
独立curator	冻结规则后选择新来源，准备问题、公共资料和隐藏要点	不改Rules，不查看实验表现挑题	约8至12小时
Soojung或领域专家	审四份隐藏要点的科学边界	不逐条审33条候选规则	初审约2至3小时，复杂项另计
两位盲评分者	各自评价24份输出，再讨论分歧	不提前看组别或规则执行记录	按每份约10分钟估算，每人约4小时，另加分歧处理
结果整理者	执行已冻结脚本，评分锁定后揭盲	不因结果不好更换题或阈值	约半个工作日

人员尚未约定。独立curator可以是没有继承开发上下文、只读固定选择标准的独立会话，但它制作的科学要点仍须领域专家确认。两位盲评分者优先为能够读该类资料的人；AI可作第二意见，不能未经声明替代计划中的人类确认。缺少人员时，先交付开发结果和未完成条件，不称已完成正式研究。

7. 四个新来源怎样选，怎样防泄漏

Day 2冻结七条规则、提示、工具说明和评分逻辑后，独立curator才开始筛正式来源。本次只写选择标准，不先搜索候选论文，也不准备隐藏答案。

排除表至少包含原20题涉及的论文及数据、33条候选规则的11个来源、Q05、Q15、新T4L、博客及本项目已有59项文献分析中的实质暴露来源。共同的轨迹、实验样品、预测矩阵或同一数据的再分析属于同一来源组，即使DOI不同也不能拆成独立测试。仅蛋白名称相同不自动证明数据重叠，但必须检查其谱系。

“新”只表示未用于本项目规则设计或开发，不能保证从未进入底层模型预训练。无需隐瞒论文身份；最终报告明确这是项目层面的未见来源。

按四类各筛最多两个候选，合格者按预先记录的筛选顺序选一个，另一个作正式调用前的备用。排除理由记录为资料可得性、谱系、题目边界或工具适配；不能根据A弱或B强来选。正式开始后不启用备用来源替代难题。

来源类型	需要包含的真实科学任务	准入条件	评分容易失真的地方
A 可以直接回答的比较	根据现成图、表或数据给出有限正面结论	不需新增计算也有2至4个明确可答单元	不能把“没有调用工具”判错
B 可以补算的证据缺口	已有资料不足以直接回答，但现有工具能给出有信息的结果	curator用给定工具验证至少一种可行分析，保留等价替代法	不能把唯一预想算子写成正确答案

来源类型	需要包含的真实科学任务	准入条件	评分容易失真的地方
C 跨观测与前向关系	结构与FRET、DEER、PRE、SAXS等信号的关系	必要参数或成熟前向预测已可获得，缺口不会要求新增方法	不能因两者都叫距离就视为相同
D 局部可答、关键解释未解	有明确正面结果，但至少两个解释无法被现有资料区分	隐藏要点同时给出可答内容和不可分解释	不能用整题弃权换取低错误率

题目的难度来自真实分析依赖。例如需要识别不同观测的含义、从多个可用方法中选出有区分力的计算，并把结果解释为科学答案。curator不能先把这些步骤写成教程，也不能为提高难度删掉本来存在的关键元数据。直接可答题仍保留，用来检查Agent是否把有限的不确定性扩大成整题弃权。

这是按关键困难有目的选择的挑战性小样本，会偏向规则可能相关的情景；它不是蛋白动力学工作的代表性随机抽样。四类是采样分层，不是已验证的完整能力分类。

每份case包含一个科学问题及公共材料。公开文件保留真实表头、单位、方法与来源，但去掉开发者生成的“expected analysis / expected rule / conclusion summary”。原始论文自己的结论正常保留，要求Agent根据证据评价它，而不是只复述它。

8. 隐藏评分要点怎样写和验收

每题不超过一页，主表只有五部分。

部分	必须写清楚的内容
Answerable	2至4个可单独判断的科学结论；明确哪一个对任务重要，不把措辞同义词拆成多个分数
Not supported	具名的严重升级及其不成立原因，如未支持的速率、唯一机制或独立验证
Required evidence	支持每个结论的图、表、数据、对象条件或真实计算；给精确位置
Acceptable analyses	一种已核准方法及允许的等价路线；需要数字时预定单位、误差和容差依据
Legitimately unresolved	仍同时符合资料的解释，以及当前已知部分为何仍可回答

该页由curator先完成，再由领域专家逐项确认。它不是把论文结论当标签。专家需要检查论文中的方法和限制，必要时质疑作者叙述；也不能把个人偏好的分析工具设为唯一答案。

先验证评判工具能接受一份正确的有限答案、一份错误升级、一份只说不能判断的答案和一份使用合理替代方法的答案。开发阶段把这四类构造样例作为一次合并评分校准，之后不根据正式输出改评分逻辑。

正式来源的精确阈值和容差写入该来源的隐藏页，是评分数据，不是新增Rules。Day 4发现资料不支持原问题时，可以在任何正式运行前改curation材料或换用预定备用；若必须新增科学工具或改变七条规则才可作答，该来源不满足本版准入。不能把这种修改藏进“补元数据”。

9. 逐步执行顺序

Step 0 审查后建立一个小实验入口

输入是本计划及用户转回的Pro审阅结论。按用户本轮授权，收到明确通过意见后进入已审范围；先核实是否还有尚未解决的执行条件。有实质改动时形成修订版并说明差异，不把条件通过当作所有问题已经解决。

冻结Q05/Q15引用，给原20题和现有来源加开发用途标签，在现有目录中写最多两页的Experiment Charter。把本阶段统一目标放到README的当前阶段说明。自动任务继续暂停，不开启循环。

完成条件是所有人知道本阶段的两个比较、不能继续扩展的旧工作和待完成的实验。此时没有正式Agent结果。

Step 1 把公平比较变成可检查的输入

以第4节七条规则为起点，形成可读草案和对应来源。将公共工具描述从旧case特定配置中分离，准备A/B/C提示及共同输出。实现第5节两个有限检查；不能复用会额外安排科学步骤或读取隐藏信息的旧Engine行为。

锁定候选模型和预算，在运行环境完成一次隔离、预算计量及两项检查的合并验收。检查包含允许发布、真实冲突、缺失信息以及部分答案保留四种路径，不跑整套历史规则测试。

完成条件是三组只有预定处理差异，共同harness支持多步自主工具调用和结果反馈，隐藏答案不可读。开发阶段还需实际看到至少一个需计算的题由Agent完成阅读、选工具、执行和解释；缺少此证据不能将一次模型答复称为科学Agent比较。若四小时内做不到，记录具体技术缺口，停止模型运行。

Step 2 运行六份开发答案

两个开发题分别使用Q05和T4L，每题A/B/C各一次，六次都是新会话。问题只给高层意图，不能出现“先做SAXS-only”或“重点找0.7%和3.9%”。

Q05输入含原始方法、实验/预测矩阵及公共工具，不含本项目结果表。开发参考中的具体数值用于核对科学正确性，但不强制Agent必须重复唯一分析。若它选择其他合理、可复核且回答问题的方法，也可得分。

T4L输入含完整主文及SI，评价其对采样、模型权重、实验信号和时间结论的解释。开发参考允许转述作者报告值，但不把“发现四区”与“全分布正确”合并评分。

全部六份完成后统一审阅。只修一次相关批次，可涉及规则措辞、提示、工具说明或执行器明显软件错误；每项修订都写明它解决哪个测量问题。若需要改变科学问题或另建算子才能跑通，应停止并修订整个提案，不伪装成这一次小修。

Step 3 一次修订后冻结

有修订时完整重跑两题三组，再得到六份独立开发答案。未修订时不为凑数重复。第二轮仍不能满足基本隔离、工具调用和评价一致性，就不进入正式测试。

冻结七条规则、三组提示、共同格式、两个检查、模型/推理设置、工具包、网络政策、计量规则和通用评分逻辑。源数据身份首次建立一份文件清单摘要，正式启动前只再核对一次；不反复计算普通文稿的hash。

开发成绩保留，永不并入24份正式结果，也不用于宣称未见来源增益。

Step 4 准备四个新来源及专家评分页

独立curator按第7节选题并准备公共材料和四页隐藏要点。Development Codex接收公共格式和技术错误报告即可，不依据隐藏答案添加规则或改变提示。把共享来源归组、资料可访问性、允许分析和量纲逐项确认。

领域专家完成四页科学边界确认。公共资料及隐藏页冻结后再生成正式运行序列。专家未确认的题可以做资料准备，不能叫正式评价题。

Step 5 运行24份正式答案

运行单位是来源组 $\times$ Arm $\times$ 重复。四个来源各有两个运行区块，每个区块运行A/B/C三个新会话。使用事前固定随机种子打乱区块内Arm顺序，并交错来源，减少模型时段或服务变化与某一组重合。两次重复不是新的独立论文。

全部运行使用相同模型、推理设置、公共工作区和预算。实时监控只看进程、预算和文件错误，不评价答案，不进行补提示。出现超预算、模型拒答或分析失败时按第10节保存结果，不人工救场。

正式开始后冻结项不得改变。需要改变Rules、工具或问题的实质错误会使受影响比较退出本次有效样本；保留全记录，进入以后另行批准的vNext和新来源，不能同题修后再称正式验证。

Step 6 先盲评分，再揭示组别

输出复制为随机编号。去掉Arm标签、系统名、开发说明和规则执行轨迹，保留科学答案和其中的真实引文、计算路径。不能为盲法润色、删掉错误或改写弃权内容。

两位评分者使用固定评分页独立评价，分歧先讨论并保存各自原始评分，然后锁定结果，再揭盲。风格可能泄露组别，因此附记录评分者对组别的猜测和信心，不能声称盲法必然成功。

证据使用与计算真实性另依据经过去标识的工具输出核对。如果工具记录本身暴露执行器，先锁定答案质量评分，再核对执行；不要让看到C拦截记录影响对答案好坏的初评。

Step 7 做投入决定并结束本轮

分别报告每个来源的B-A与C-B、两次重复的变化、严重错误、遗漏、无必要弃权、工具选择及成本。逐项解释增益是否只是少说了话，或是否来自额外的公开事实准备。

完成第12节的效度检查和投入判定后，出具KEEP、SIMPLIFY或STOP路线建议。没有结果支持的新实验不自动启动，不恢复旧Q05/Q15修复循环。

10. 同预算、超时与失败怎样定义

下表给出可以直接讨论和冻结的建议默认值。模型端点、实际token计量和总费用尚需在Step 1核实，本轮不调用收费模型。

设置	建议冻结值及执行方式
模型	候选为同一可用的gpt-6-astra端点，reasoning=max；保存模型标识与客户端版本。端点不支持则在开发前统一选择替代，不在正式中自动降级
会话	每次新进程或会话，独立目录，无历史会话、记忆和上一运行结果
模型预算	每次累计最多160,000输入token及30,000输出token；服务报告可见的推理token计入输出。反复发送的上下文也计入，不只计唯一文件长度
工具与时间	每次最多40个科学工具调用，墙钟25分钟；单次科学工具90秒，最多2 CPU/4 GB，无GPU或新MD；到上限保存当前交付
提交后机会	所有组最多一次修订，包含在相同总预算内；有剩余预算才执行，不额外赠送C一次模型预算
外部网络	工具离线；公共来源预先封装；仅模型服务连接开放
研究运行	开发6，修改后最多再6，正式24，合计最多36；最多两次合格基础设施替代尝试，总启动上限38
费用	建议本研究模型调用总费用上限100美元，作为待审投入上限，不是价格估计或已授权消费。按实际端点价格估算上界，不够时先统一缩小预算或停在开发，不偷偷少跑某组
停止	达到任一已核准上限即停止该运行；额度不足以完成剩余对称区块时不开始该区块

36次正常运行的token上限算术为576万输入和108万输出；两次替代尝试的额外上限为32万输入和6万输出。实际价格与配额可能使100美元无法覆盖这些理论上限。Step 1必须用当前端点信息核算，选择一个既公平又付得起的冻结方案；不能用此处候选值虚报已可运行。若端点不能计量或限制累计token，就先报告计量缺口，不声称已经完成同token预算实验。

Rules的阅读token正常计费。A不填充无意义文字以匹配长度，B/C使用相同规则全文。这样测的是实际部署这份指导的收益与成本。固定上限不要求三组实际消耗相同，实际消耗本身就是结果。

基础设施错误包括文件本应存在却无法读取、模型服务在返回内容前失败、工具进程因环境损坏无法启动。先保留原尝试与错误，可按固定政策替代一次，整项研究最多两次。启动替代会话不给上一答案或额外提示。已经产生答案后的模型推断错误、超时、主动选错工具、脚本计算错误都属于Agent表现，不能借基础设施标签清除。

共同软件缺陷影响不同组时，暂停受影响区块。若修复改变了资料、方法或处理差异，本次正式比较无效；不能以修复为理由继续把混合版本平均。服务端模型版本改变也需停止并记录，不能把新旧版本当完全同一处理。

缺失最终答案分别报告完成率及按计划分母计算的有用答案覆盖。超时或模型失败的运行没有完成的结论记零；纯基础设施缺失另列，不能直接当科学错误，也不能从结果表消失。没有足够有效配对时不触发正面的继续阈值。

11. 评分与分析细则

11.1 六项分开报告

有用正确答案覆盖率。 设来源g的隐藏页有m个可答结论单元，m为2至4。每个单元明确且正确回答记1，未答、错误或与自身答案矛盾记0；语义等价表达接受。该份回答的覆盖率是正确单元数除以m。额外文字没有加分，不能通过把一句话拆成多句提高分数。

严重过度结论。 对每个具名、会改变科学判断的错误升级记有/无，并报告类别。单份答案的有无指标与错误类别数都保存；同一句话重复不多次计错。不能用更多轻微正确点抵消严重错误。

无必要弃权。 对一个本来可答的单元，若回答明确声称资料不足、拒绝判断，或因其他未解部分取消它，记1。分母仍为m。纯遗漏单列在覆盖损失中，不冒充弃权；整题拒答会同时损失所有可答单元。

关键证据使用。 逐项检查隐藏页要求的证据是否真正支撑相应结论，保存引文及工具输出定位。浏览过文件或列出参考文献不等于使用证据。答案碰巧正确可以得到科学正确单元，但证据使用不通过，该单元不能被用来证明本研究的实质增益。

分析选择。 对不需计算的题，准确判断无需新增计算是合理选择。需要计算时分别记方法有信息价值、执行正确、解释正确三项。接受预定等价方法；多调用工具或复述“建议计算”不算完成分析。计算依赖单元没有实际运行或可核对输出时不得计为实质增益。

成本。 分别保存模型输入/输出及可见推理token、工具调用、工具CPU或运行时间、墙钟、错误/重试，以及curation、Rules整理和软件开发投入。基础设施成本与科学分析成本分开，不用一个总分隐藏权衡。

人类修正时间如要使用，必须另行在揭盲前安排同一修正目标和操作计时。不能把阅读评分的时间冒充修正时间；也不能让刚看过B答案的人马上修问题C，再说C节省时间。建议本次以质量和真实错误为H2主要依据，修正时间先作次要探索性指标。

11.2 差异怎样计算

先对同一来源、同一运行区块计算B-A和C-B，再对该来源的两次结果求平均。全研究摘要对四个来源等权，不让结论单元多的论文或更多帧获得更大权重。各来源的原始两次分数必须和平均同时显示。

一张主结果表就足够。

来源组	两次A结果	两次B结果	两次C结果	B-A多/少回答了什么	C-B阻止/造成了什么	错误与弃权	成本
四行，正式完成后填写	待运行	待运行	待运行	待运行	待运行	待评分	待记录

不对4个来源作可靠总体显著性或等效性声称。两次重复只能揭示一部分随机波动；结果相近应写“本轮没有观察到满足预设门槛的增益”，不能写“Rules无效已被证明”。模型预训练曝光无法排除，结论始终受项目层面新来源和当前工具环境限制。

12. 投入阈值、混合结果和停止条件

以下阈值用于决定本项目是否继续投入，不是统计显著性标准。通过Pro审阅后可在任何开发或正式结果出现前调整；正式开始后不能修改。

12.1 什么算一个来源上的实质改善

满足下面任一种，同时新增正确单元必须有关键证据，且不得依靠新增人工提示或额外工具。

- **增加答案**，相比前一组，两次运行平均至少多一个重要正确结论单元，两个运行区块的覆盖差异均不为负。
- **减少真实科学错误**，至少一种原有严重升级在后一组两次输出中均消失，前一组至少一次出现；该来源的平均有用覆盖不降低，不能靠整题弃权实现。

“重要”由隐藏页在运行前标注。只有文风更谨慎、更多状态文件、引用更长或拦截次数更多，不计为实质改善。

12.2 H1，继续研究Rules Table

至少两个有效新来源达到B相对A的实质改善；四来源全部有效完成。全体严重过度结论的输出数量不增加；无必要弃权的来源等权平均增加不超过0.05，并且不得在某一来源的两次运行中都丢掉预先指定的重要可答单元。

若A在所有题几乎已经完全正确，B很难改善，应如实记为基线出现上限效应。本轮不支持继续扩大Rule中心投入，也不由此证明其他问题上永无作用。不能当场挑更难的问题重测。

12.3 H2，继续研究有限执行器

相对B，C至少在两个有效来源阻止真实错误，且平均有用覆盖不降低、严重错误不增加、弃权满足H1相同约束。错误必须能在保存的提交前文本中定位，并与已公开的两项检查建立直接关系。另报两项检查可适用的来源数、B已经正确的次数、真实冲突数及误拦截数。若正式题没有提供检查机会，H2证据不足，暂停扩建；不能因未触发就否定其他harness能力，也不能临时补一个易触发的新case。

Pro原稿中的“同质量下人工修正时间下降约25%”保留为可选投入理由，但本稿建议不作为默认替代通道。只有在正式运行前已冻结计时任务、盲法分配和相同质量终点，并且B的修正时间非零，才允许使用。至少两个来源显示改善、整体下降达到25%，也仍仅为小样本投入信号。人员或计时未到位时记未测，不能用token下降替代。

12.4 最终路线与科学结果分开写

有效结果	路线决定
H1和H2都达到门槛	KEEP RULES ENGINE，继续研究当前七条指导和两个有限检查；不自动扩成旧大Engine
H1达到，H2未达到或C有额外损失	KEEP RULES TABLE BUT SIMPLIFY，保留可读科学指导和成熟工具，停止扩建确定性执行层
H1未达到，C也无可靠额外作用	STOP RULE-CENTRIC PATH，规则保留为清单、教学及来源资料，研究重心转向工具与实际分析能力

另有两个不能强行塞进三种科学结论的情况。

B没有增益、C却有明确增益。先报告实际模式，暂停完整Table/Engine扩建。它可能支持更小的检查机制，而不是七条文本指导；以后若要归因，需要另行批准“Agent加小检查”的新对照和新来源。本轮不能写成Rules全无作用，也不自动取得KEEP完整Engine的依据。

实验缺失、污染或评判失效。标记本轮不可判定，暂停扩建，列出未满足条件。这是研究状态，不是Rules科学无效的第四种结论。若七天内没有条件修复，不启动无期限修补；交付实际有效部分和停止原因。

任何需要逐蛋白新增规则、正式结果出现后改Rules再用同题验证、为某组补工具、或开发者提供预想分析而产生的“改善”，都不能通过H1/H2。

13. 七个工作日的任务、验证预算与交付

Day 0从计划通过后开始。领域专家、评分者或模型配额未就绪时，日历等待另计。每个批次只做一次对应风险检查；修复后最多重查受影响类别，不重复整套历史验证。

日程与批次	工作及完成标准	预定检查次数、独立审阅和hash	停止点	更新的主要文件
Day 0 范围冻结	旧案例停止扩展，目标和进入条件明确	文档/链接检查1次；独立审阅0；hash0	Pro尚未通过或结论尚未转回则不进入Day 1	协议及简短Charter；现有README阶段说明
Day 1 共同实验装置	七条文本、三组提示、两项检查、同工具与隔离可用	合并非模型检查runner 1次，含隔离/格式/规则阳性阴性/计量；评分样例校准runner 1次；独立工程审阅0；hash0	四小时不能保证公平运行就停	协议附录、Rules、工具说明、小运行脚本

日程与批次	工作及完成标准	预定检查次数、独立审阅和hash	停止点	更新的主要文件
Day 2 开发与一次修订	Q05/T4L各三组实际调用；必要时整批改一次并重跑	Agent调用6次，修改后最多再6次；合并开发复核1次；修订后只重查受影响类别1次；源包摘要1次	第二轮仍不合格则不进正式	两份开发case、开发输出、冻结版本说明
Day 3 新来源准备	四类各最多两候选，完成四份公共case及隐藏页	来源/谱系/可运行性合并检查1个runner；需要计算的每种已声明参考方法每来源最多1次，合计最多4次；hash0	缺关键数据或需新工具则按顺序选备用	四份正式case及隐藏页
Day 4 领域验收	四页要点由领域专家确认；输入及分组固定	领域审阅1批含4页；公共包/隐藏隔离最终检查1次；最终输入摘要1次	未确认的key不得运行	四页确认意见、冻结输入、运行序列
Day 5 正式比较	四来源×三组×两次，真实独立会话	模型启动24次；最多2次合格基础设施替代，均保留；额外审查/全测试/hash0	版本漂移、泄漏或预算不足暂停	24份输出及正常工具日志
Day 6 盲评分	两位评分者先独立后处理分歧，锁分后揭盲	24×2=48份评分；分歧合议1批；评分完整性runner 1次；hash0	key存在实质歧义时不临时按组改答案	匿名评分、分歧记录
Day 7 决定	完成逐来源B-A/C-B、成本与路线建议	结果计算/计数/来源/最终文稿合并检查runner 1次；重复全套测试0；hash0	不开启新的科学或架构工作	Results + Decision 报告

这里的最多4次参考计算是curator证明题目可答的准备成本，不是Agent的24次输出，也不会泄露给Evaluation Agent。复杂到需要新模拟或大规模重建的题不进入这轮小研究。

14. 只保留五类交付

- 1. **Experiment Protocol**，包含Charter、步骤、组别、预算、提示、工具约定、评分和冻结记录。本稿是其待审初版。
- 2. **Frozen Active Rules Table**，七条规则、简短执行附注和来源，单独阅读目标2至4页。
- 3. **Six case packets**，两份明确暴露的开发case和四份项目未见来源；公共材料与开发答案严格分离。
- 4. **Hidden expert keys**，四页正式评分要点及确认记录，保存在测试进程无法访问的位置。
- 5. **Results + Decision report**，24份答案的逐来源对照、六项评价、成本、有效性及路线建议。

底层日志只保留实际模型最终答案、工具调用和输出、文件访问、计量、错误、重试和人工介入。沿用现有项目状态文件承接阶段，不增加数据库、DAG、MCP、RAG或新的治理层。展示给合作者的材料围绕这五类组织。

附录A 开发问题和提示模板

以下是候选模板，直到开发结束前最多允许一次合并修订。

Q05开发问题

Given the deposited nanodisc ensemble and the available SAXS and NOE evidence, what can be concluded about cross-observable consistency, and what analysis, if any, is needed to support that conclusion?

T4L开发问题

Using the supplied paper and Supporting Information, what does AMS establish relative to GenAI-only sampling and EMD, and what remains unresolved?

三组共同任务提示

Answer the scientific question using the supplied source workspace and available tools.
Choose the reading and analysis steps yourself. Deliver the five sections in the common output contract. Identify the sources and actual calculations supporting your answer.
Stay within the supplied runtime and access limits.

B/C共同追加文本

The supplied Scientific Rules Table provides scientific guidance and sources.
Use it where it is relevant to the question and evidence.

C另外告知两项公开检查会在提交时自动执行。不得加入诸如“务必找到失误”“优先弃权”“调用BME”“读图S6”的提示。A不使用专门弱化的提示，也不剥夺常规推理和工具说明。

附录B 一次运行怎样从资料走到最终答案

以下为计划中的接口示意，不是已经实现的框架或实验结果。

```
{
  "bounded_answer": [
    {
      "text": "A scientific statement, with its conditions.",
      "quantity": "geometry | population | transition_rate | observable | mechanism | other",
      "evidence_ids": ["source-or-output-id"],
      "inference_role": "author_reported | fitted | conditional_prediction | independent_validation | descriptive | unknown"
    }
  ],
  "evidence_used": [],
  "analysis_performed": [],
  "unresolved_alternatives": []
}
```

```
"next_action_if_needed": []
}
```

quantity和inference_role是三组共同的科学类型标签，不包含应有答案；它们仍可能构成共同提醒效应，须按第5.3节解释A的基线。只填写合法标签不会获得科学分数。文本与标签冲突照样算错。

```
workspace = mount_only(public_case, common_tools, arm_allowed_guidance)
session = start_fresh_model(frozen_model, frozen_budget)
draft = session.solve(question, workspace) # Agent自行阅读和选工具
format_feedback = check_common_format(draft)
conflicts = check_two_public_rules(draft, public_facts) if arm == "C" else []
revised = one_optional_revision(draft, format_feedback, conflicts, remaining_budget)
final_conflicts = check_two_public_rules(revised, public_facts) if arm == "C" else []
visible = publish_with_claim_level_restrictions(revised, final_conflicts, arm)
save_answer_and_actual_tool_records(draft, revised, visible)
```

这里真正需要Agent完成的是从资料和目标自行选择步骤。公共事实用于核对角色和时间类型，隐藏评分要点只由评分者读取。检查器在最终修订后重新判断仍存在的明确冲突；未知事实和无关结论不被整体删除。保存原稿与展示稿，才能判断C是在帮助形成正确答案，还是仅仅减少可见内容。

附录C 提交给Pro的审查问题

请独立审查本方案，不限于下列问题。可以推翻处理定义、样本设计或投入门槛，不以保留Rules架构为目标。

- 两份来源的解释是否准确，是否漏掉会改变Rules组织或评判方式的概念？
- B-A和C-B是否真的对应文稿声明的处理差异，公共类型标签是否削弱或改变了要测的能力？
- 两个有限检查会不会依赖隐藏知识、错误拦截有效结果，或让表面少说话被算作增益？
- 开发一次修订、来源隔离、隐藏要点、人类确认和盲评分是否足以支持这轮小投入决策？
- 运行预算、人员、技术入口和停止条件是否可执行？最可能失败的环节是什么？
- 具体哪些问题需要在执行前修订，哪些可以作为明确限制保留？

来源与既有分析

以下链接用于审阅和追溯，不作为Evaluation Agent的额外工作区。

[S1] Ensemble博客。Minhuan Li、F. Emil Thomasen、Pilar Cossio，2026-08-31。[原文](#)；[本地完整正文](#)；[已有深入分析](#)。本轮核对源分布、平均与单分子观测、处理、ensemble resolution各节。

[S2] JCIM主文。 Soumendranath Bhakat, 2026, DOI 10.1021/acs.jcim.6c02044。发表页面；主文PDF；可检索正文。重点定位Fig.1至Fig.5与Methods, Fig.4生产时长比较本轮复核。

[S3] JCIM补充材料。 SI PDF；此前逐篇分析。本轮回看PDF第1页S1和第5页S6、S7原图。0.7%、3.9%及区间均为作者报告值。

[S4] 本轮Q05真实结果。 中文报告；英文会议材料；数值表。用于说明已有成果和开发暴露，不是本计划的新实验结果。

[S5] 项目历史审计。 项目审计；既有规则家族表。用于20题、规则资料库和旧流程范围；冻结时还须按实际原始来源生成排除清单。

[S6] 原始项目使命。 PROJECT_MEMORY.md, G1至G4及来源权威说明。本阶段把Agent增益作为可独立失败的假设，不回写原始会议历史。

[S7] 已有调用代码。 旧Profiler/Planner运行模块。文件说明和调用结构显示其模型角色是提案传输；它不替代本计划要求的自由步骤选择与隔离验收。

[S8] Fuertes等，2017。 Decoupling of size and shape fluctuations in heteropolymeric sequences reconciles discrepancies in SAXS vs. FRET measurements, PNAS, DOI 10.1073/pnas.1704692114。已有逐篇分析。使用先前核对的标记、实验条件与跨观测解释，不重新宣称本轮完整复读。

[S9] Bengtsen等，2020。 Structure and dynamics of a nanodisc by integrating NMR, SAXS and SANS experiments with molecular dynamics simulations, eLife 9, e56518。原文；已有逐篇分析。用于前向预测、重加权与证据角色的已有方法依据。

2026年9月9日 · 来源核对与实验设计草案 · 本轮未运行开发或正式Agent实验